

1 引论

1.1 向量和矩阵范数

1.1.1 向量范数的定义

称 \mathbb{R}^n 上的一个函数 $\|\cdot\|$ 为范数, 若满足:

1. 非负性 $\|\mathbf{x}\| \geq 0$, $\|\mathbf{x}\| = 0$ 当且仅当 $\mathbf{x} = \mathbf{0}$
2. 齐次性 $\|\alpha\mathbf{x}\| = |\alpha|\|\mathbf{x}\|$, $\alpha \in \mathbb{R}$
3. 三角不等式 $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

常见的向量范数有:

- 1-范数 $\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$
- 2-范数 $\|\mathbf{x}\|_2 = (\sum_{i=1}^n |x_i|^2)^{\frac{1}{2}}$
- ∞ -范数 $\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$

1.1.2 向量范数的性质

向量范数的等价性 对于 \mathbb{R}^n 中的任意两种范数 $\|\mathbf{x}\|_\alpha$ 和 $\|\mathbf{x}\|_\beta$, 都存在两个正数 c_1, c_2 , 使得对任意 $\mathbf{x} \in \mathbb{R}^n$ 都有

$$c_1 \|\mathbf{x}\|_\alpha \leq \|\mathbf{x}\|_\beta \leq c_2 \|\mathbf{x}\|_\alpha$$

证明. 令 $f(\mathbf{x}) = \|\mathbf{x}\|_\beta$, $\mathbf{S} = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_\alpha = 1\}$ 为一个有界闭集, 则连续函数 $f(\mathbf{x})$ 在 \mathbf{S} 上存在最小值 $c_1 = \min_{\mathbf{x} \in \mathbf{S}} f(\mathbf{x})$ 和最大值 $c_2 = \max_{\mathbf{x} \in \mathbf{S}} f(\mathbf{x})$ 。对于 $\mathbf{x} \neq \mathbf{0}$ 有 $\frac{\mathbf{x}}{\|\mathbf{x}\|_\alpha} \in \mathbf{S}$, 则有

$$c_1 \leq f\left(\frac{\mathbf{x}}{\|\mathbf{x}\|_\alpha}\right) = \frac{\|\mathbf{x}\|_\beta}{\|\mathbf{x}\|_\alpha} \leq c_2$$

即

$$c_1 \|\mathbf{x}\|_\alpha \leq \|\mathbf{x}\|_\beta \leq c_2 \|\mathbf{x}\|_\alpha$$

□

对于常用的向量范数，有如下关系：

$$\|\mathbf{x}\|_2 \leq \|\mathbf{x}\|_1 \leq \sqrt{n}\|\mathbf{x}\|_2$$

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_1 \leq n\|\mathbf{x}\|_\infty$$

$$\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{n}\|\mathbf{x}\|_\infty$$

向量序列的收敛性 在空间 \mathbb{R}^n 中，向量序列 $\{\mathbf{x}^{(k)}\}$ 收敛于向量 \mathbf{x}^* 的充要条件是存在范数 $\|\cdot\|$ 使得

$$\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| = 0$$

压缩映射 设有非空集合 $\mathbf{D} \subset \mathbb{R}^n$ ，对于映射 $\mathbf{f}: \mathbf{D} \rightarrow \mathbf{D}$ ，若存在范数 $\|\cdot\|$ 和常数 $q \in [0, 1)$ 使得对任意 $\mathbf{x}, \mathbf{y} \in \mathbf{D}$ 都有

$$\|\mathbf{f}(\mathbf{x}) - \mathbf{f}(\mathbf{y})\| \leq q\|\mathbf{x} - \mathbf{y}\|$$

则称 \mathbf{f} 为 \mathbf{D} 上的压缩映射。

Banach 压缩映射原理 设 $\mathbf{D} \subset \mathbb{R}^n$ 为闭集，映射 \mathbf{f} 为 \mathbf{D} 上的压缩映射，则 \mathbf{f} 在 \mathbf{D} 上有唯一不动点 \mathbf{x} ，使得 $\mathbf{f}(\mathbf{x}) = \mathbf{x}$ 。

证明. 设 $\mathbf{x}^{(0)} \in \mathbf{D}$ ，构造序列 $\{\mathbf{x}^{(k)}\}$ 如下：

$$\mathbf{x}^{(k+1)} = \mathbf{f}(\mathbf{x}^{(k)}), \quad k = 0, 1, 2, \dots$$

则对任意 $k \geq 0$ ，有

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| = \|\mathbf{f}(\mathbf{x}^{(k)}) - \mathbf{f}(\mathbf{x}^{(k-1)})\| \leq q\|\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}\|$$

由此可得

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq q^k \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|$$

对于 $m > n \geq 0$ ，有

$$\|\mathbf{x}^{(m)} - \mathbf{x}^{(n)}\| \leq \sum_{k=n}^{m-1} \|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| \leq \sum_{k=n}^{m-1} q^k \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\| = \frac{q^n - q^m}{1 - q} \|\mathbf{x}^{(1)} - \mathbf{x}^{(0)}\|$$

由于 $q \in [0, 1)$ ，当 $n \rightarrow \infty$ 时

$$\lim_{n \rightarrow \infty} \|\mathbf{x}^{(m)} - \mathbf{x}^{(n)}\| = 0$$

即序列 $\{\mathbf{x}^{(k)}\}$ 为 Cauchy 序列, 故在 \mathbb{R}^n 中收敛, 设其极限为 $\mathbf{x}^* \in \mathbf{D}$, 则由映射的连续性可得

$$\mathbf{x}^* = \lim_{k \rightarrow \infty} \mathbf{x}^{(k+1)} = \lim_{k \rightarrow \infty} \mathbf{f}(\mathbf{x}^{(k)}) = \mathbf{f}(\lim_{k \rightarrow \infty} \mathbf{x}^{(k)}) = \mathbf{f}(\mathbf{x}^*)$$

即 \mathbf{x}^* 为 \mathbf{f} 的不动点。设存在不动点 $\mathbf{x}_1, \mathbf{x}_2$, 则有

$$\|\mathbf{x}_1 - \mathbf{x}_2\| = \|\mathbf{f}(\mathbf{x}_1) - \mathbf{f}(\mathbf{x}_2)\| \leq q\|\mathbf{x}_1 - \mathbf{x}_2\|$$

由于 $q \in [0, 1)$, 上式只在 $\mathbf{x}_1 = \mathbf{x}_2$ 时成立, 故不动点唯一。

□

1.1.3 矩阵范数的定义

称 $\mathbb{R}^{n \times n}$ 上的一个函数 $\|\cdot\|$ 为范数, 若满足:

1. 非负性 $\|\mathbf{A}\| \geq 0$, $\|\mathbf{A}\| = 0$ 当且仅当 $\mathbf{A} = \mathbf{0}$
2. 齐次性 $\|\alpha\mathbf{A}\| = |\alpha|\|\mathbf{A}\|$, $\alpha \in \mathbb{R}$
3. 三角不等式 $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$
4. 矩阵乘法不等式 $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$

常见的矩阵范数有:

- 列范数 $\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$
- 行范数 $\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$
- 谱范数 $\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}$
- F-范数 $\|\mathbf{A}\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2}$

1.1.4 矩阵范数的性质

算子范数 称向量范数导出的矩阵范数为算子范数, 定义如下:

$$\|\mathbf{A}\| = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|\mathbf{Ax}\|$$

由定义可知算子范数是矩阵范数, 且与向量范数相容:

$$\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$$

矩阵范数的等价性 对于 $\mathbb{R}^{n \times n}$ 中的任意两种范数 $\|\mathbf{A}\|_\alpha$ 和 $\|\mathbf{A}\|_\beta$ ，都存在两个正数 c_1, c_2 ，使得对任意 $\mathbf{A} \in \mathbb{R}^{n \times n}$ 都有

$$c_1 \|\mathbf{A}\|_\alpha \leq \|\mathbf{A}\|_\beta \leq c_2 \|\mathbf{A}\|_\alpha$$

对于常用的矩阵范数，有如下关系：

1.

$$\frac{1}{n} \|\mathbf{A}\|_\infty \leq \|\mathbf{A}\|_1 \leq n \|\mathbf{A}\|_\infty$$

证明. 对于任意 $a_{ij} \in \mathbf{A}$ ，有

$$|a_{ij}| \leq \|\mathbf{A}\|_\infty$$

则有

$$\sum_{i=1}^n |a_{ij}| \leq n \|\mathbf{A}\|_\infty$$

取最大值可得

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \leq n \|\mathbf{A}\|_\infty$$

同理可得

$$\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \leq n \|\mathbf{A}\|_1$$

□

2.

$$\frac{1}{\sqrt{n}} \|\mathbf{A}\|_\infty \leq \|\mathbf{A}\|_2 \leq \sqrt{n} \|\mathbf{A}\|_\infty$$

证明. 先证明 $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2 \leq \sqrt{n} \|\mathbf{x}\|_\infty$ ：

对于任意 $x_i \in \mathbf{x}$ ，有 $|x_i| \leq \|\mathbf{x}\|_2$ ，取最大值可得 $\|\mathbf{x}\|_\infty \leq \|\mathbf{x}\|_2$

对于任意 $x_i \in \mathbf{x}$ ，有 $|x_i| \leq \|\mathbf{x}\|_\infty$ ，则有 $|x_i|^2 \leq \|\mathbf{x}\|_\infty^2$ ，对所有 i 求和可得 $\|\mathbf{x}\|_2^2 \leq n \|\mathbf{x}\|_\infty^2$ ，即 $\|\mathbf{x}\|_2 \leq \sqrt{n} \|\mathbf{x}\|_\infty$

由算子范数定义可得

$$\|\mathbf{A}\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2}, \quad \|\mathbf{A}\|_\infty = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty}$$

对于任意 $\mathbf{x} \neq \mathbf{0}$, 有

$$\frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} \leq \frac{\sqrt{n}\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_2} \leq \frac{\sqrt{n}\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty} \leq \sqrt{n}\|\mathbf{A}\|_\infty$$

取最大值可得

$$\|\mathbf{A}\|_2 \leq \sqrt{n}\|\mathbf{A}\|_\infty$$

对于任意 $\mathbf{x} \neq \mathbf{0}$, 有

$$\frac{\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty} \leq \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_\infty} \leq \sqrt{n} \frac{\|\mathbf{Ax}\|_2}{\|\mathbf{x}\|_2} \leq \sqrt{n}\|\mathbf{A}\|_2$$

取最大值可得

$$\|\mathbf{A}\|_\infty \leq \sqrt{n}\|\mathbf{A}\|_2$$

□

1.2 误差

1.2.1 误差的类型

误差描述了数值计算中近似解的精确程度, 可分为以下几类:

- **截断误差** 在数值运算中运用近似方法表示准确数值运算或数量而引起的, 也叫方法误差。
- **舍入误差** 由于计算机字长的限制而产生的误差。
- 不与数值方法相关的误差, 如测量误差等。

1.2.2 误差的度量

绝对误差 设 x^* 为精确值, \tilde{x} 为近似值, 则称 \tilde{x} 的绝对误差为

$$E(\tilde{x}) = x^* - \tilde{x}$$

绝对误差具有量纲, 反映了近似值与精确值之间的差距, 但不能很好地反映近似值的精度。

绝对误差极限 若 $\exists \delta > 0$, 使得 $|E(\tilde{x})| = |x^* - \tilde{x}| \leq \delta$, 则称 δ 为 \tilde{x} 的绝对误差极限。

相对误差 设 x^* 为精确值, \tilde{x} 为近似值, 则称 \tilde{x} 的相对误差为

$$E_r(\tilde{x}) = \frac{x^* - \tilde{x}}{\tilde{x}} \times 100 \quad (x^* \neq 0)$$

相对误差不具有量纲, 能够较好地反映误差的特性及近似值的精度。

相对误差极限 若 $\exists \delta_r > 0$, 使得 $|E_r(\tilde{x})| = \left| \frac{x^* - \tilde{x}}{\tilde{x}} \right| \leq \delta_r$, 则称 δ_r 为 \tilde{x} 的相对误差极限。

1.2.3 有效数字

如果近似值 \tilde{x} 的误差不超过某位的半个单位, 该位数字到 \tilde{x} 的第一位非零数字共有 n 位, 那么这 n 位数字称为 \tilde{x} 的有效数字。

$$\tilde{x} = \pm 10^k \times 0.a_1 a_2 \cdots a_n$$

$|x^* - \tilde{x}| \leq \frac{1}{2} \times 10^{k-n}$ 时称 \tilde{x} 是 x^* 的 n 位有效数字。

误差和有效数字的关系 由相对误差的定义 $E_r(\tilde{x}) = \frac{E(\tilde{x})}{|\tilde{x}|}$ 可知 $\delta_r(\tilde{x}) = \frac{\delta(\tilde{x})}{|\tilde{x}|}$ 。有效数字和相对误差限的关系由以下定理给出:

- 若 \tilde{x} 有 n 位有效数字, 则 $\left| \frac{x^* - \tilde{x}}{\tilde{x}} \right| \leq \frac{1}{2a_1} \times 10^{1-n}$.
- 若 $\left| \frac{x^* - \tilde{x}}{\tilde{x}} \right| \leq \frac{1}{2(a_1+1)} \times 10^{1-n}$, 则 \tilde{x} 至少具有 n 位有效数字。

1.2.4 误差的传播

函数误差的传播 若 $f(x)$ 在 \tilde{x} 的邻域上可微, 由其在 $x = \tilde{x}$ 的泰勒展开式 $f(\tilde{x}) \approx f(x^*) + f'(x^*)(\tilde{x} - x^*)$ 近似可得

$$|f(\tilde{x}) - f(x^*)| \leq |f'(\tilde{x})| \cdot |\tilde{x} - x^*|$$

由此对近似函数 $f(\tilde{x})$ 的误差限和相对误差限分别有如下估计式:

$$\begin{cases} \delta f(\tilde{x}) \leq |f'(\tilde{x})| \cdot \delta(\tilde{x}) \\ \delta_r f(\tilde{x}) \leq \left| \frac{f'(\tilde{x})}{f(\tilde{x})} \right| \cdot \delta(\tilde{x}) \end{cases}$$

对于二元函数, 若 $f(x, y)$ 在 (\tilde{x}, \tilde{y}) 的邻域上可微, 由其泰勒展开式 $f(x^*, y^*) \approx f(\tilde{x}, \tilde{y}) + \frac{\partial f(\tilde{x}, \tilde{y})}{\partial x}(x^* - \tilde{x}) + \frac{\partial f(\tilde{x}, \tilde{y})}{\partial y}(y^* - \tilde{y})$ 近似可得

$$|f(x^*, y^*) - f(\tilde{x}, \tilde{y})| \leq \left| \frac{\partial f(\tilde{x}, \tilde{y})}{\partial x} \right| \cdot |x^* - \tilde{x}| + \left| \frac{\partial f(\tilde{x}, \tilde{y})}{\partial y} \right| \cdot |y^* - \tilde{y}|$$

由此对近似函数 $f(\tilde{x}, \tilde{y})$ 的误差限和相对误差限分别有如下估计式:

$$\begin{cases} \delta f(\tilde{x}, \tilde{y}) \leq \left| \frac{\partial f(\tilde{x}, \tilde{y})}{\partial x} \right| \cdot \delta(\tilde{x}) + \left| \frac{\partial f(\tilde{x}, \tilde{y})}{\partial y} \right| \cdot \delta(\tilde{y}) \\ \delta_r f(\tilde{x}, \tilde{y}) = \left| \frac{\delta f(\tilde{x}, \tilde{y})}{f(\tilde{x}, \tilde{y})} \right| \end{cases}$$

算术误差的传播 将算术运算视为二元函数, 可以算出加减乘除运算的误差传播公式:

$$\begin{cases} \delta(\tilde{x} \pm \tilde{y}) \leq \delta(\tilde{x}) + \delta(\tilde{y}) \\ \delta_r(\tilde{x} \pm \tilde{y}) \leq \frac{\delta(\tilde{x}) + \delta(\tilde{y})}{|\tilde{x} \pm \tilde{y}|} \end{cases}$$

$$\begin{cases} \delta(\tilde{x}\tilde{y}) \leq |\tilde{y}|\delta(\tilde{x}) + |\tilde{x}|\delta(\tilde{y}) \\ \delta_r(\tilde{x}\tilde{y}) \leq \frac{\delta(\tilde{x})}{|\tilde{x}|} + \frac{\delta(\tilde{y})}{|\tilde{y}|} = \delta_r(\tilde{x}) + \delta_r(\tilde{y}) \end{cases}$$

$$\begin{cases} \delta(\frac{\tilde{x}}{\tilde{y}}) \leq \frac{1}{|\tilde{y}|}\delta(\tilde{x}) + \frac{|\tilde{x}|}{\tilde{y}^2}\delta(\tilde{y}) \\ \delta_r(\frac{\tilde{x}}{\tilde{y}}) \leq \frac{\delta(\tilde{x})}{|\tilde{x}|} + \frac{\delta(\tilde{y})}{|\tilde{y}|} = \delta_r(\tilde{x}) + \delta_r(\tilde{y}) \end{cases}$$

1.3 数值计算原则

1.3.1 适定问题

称一个数学问题是适定的, 如果它满足以下三个条件:

- 存在解
- 解是唯一的
- 解连续的取决于初边值条件

即适定问题的解满足存在性、唯一性和稳定性三个条件。否则称其为不适定问题。

1.3.2 数值稳定性

对于某个数值算法，其稳定性可分为以下几类：

- 数值不稳定：输入数据的误差在计算过程中不断扩大
- 条件稳定（相对稳定）：算法在一定条件下数值稳定
- 无条件稳定（绝对稳定）：算法在任何条件下都数值稳定

1.3.3 数值计算原则

在进行数值计算时，应遵循以下原则：

1. 避免两个相近数相减
2. 避免用绝对值过小的数做除数
3. 防止大数吃掉小数（避免对数量级差异过大的数作加减法）

除了具体运算中的误差规避，还可以从整体算法设计上控制误差：

- 简化计算步骤，提高计算效率：减少计算量和减少误差积累
- 使用数值稳定的算法：控制误差的传播